

CSet - Analisador sintático

Daniella Angelos ¹

¹Departamento de Ciência da Computação - Universidade de Brasília

1. Objetivo

Este trabalho visa apresentar o analisador sintático desenvolvido com o auxílio da ferramenta *Bison*, para a linguagem CSet proposta anteriormente.

2. Introdução

Um compilador pode ser dividido em duas partes principais: análise e síntese. A parte de análise quebra o programa fonte em pedaços com significado e aplica uma estrutura gramatical a eles, informando possíveis erros que foram encontrados. Esta parte também é responsável por coletar informações sobre o programa fonte e armazená-las em uma estrutura de dados chamada *tabela de símbolos*, que é passada ao longo das fases intermediárias da análise até a parte de síntese.

A análise sintática é uma das primeiras fases de um compilador. O parser recebe tokens passados pelo analisador léxico e determina sua estrutura gramatical de acordo com a gramática da linguagem especificada. Duas estruturas de dados são populadas durante a análise sintática: a tabela de símbolos e a árvore sintática, que futuramente serão utilizadas pelo analisador semântico.

3. Gramática

A gramática da linguagem apresentada anteriormente sofreu algumas alterações que estão destacadas a seguir.

```
Outset          -> Function
                  | Outset Function

Function         -> Type identifier ( ArgList ) CompoundStmt

ArgList          -> Arg
                  | ArgList , Arg

Arg              -> Type identifier

Declaration      -> Type IdentList
                  | Type Attr

Type             -> int
                  | float
                  | char
                  | bool
                  | set << Type >>
```

	pair << Type , Type >>
IdentList	-> identifier , IdentList identifier
Stmt	-> WhileStmt Expr ; IfStmt CompoundStmt Declaration ; IO ; ReturnStmt ;
WhileStmt	-> while (Expr) Stmt
IfStmt	-> if (Expr) CompoundStmt if (Expr) CompoundStmt ElsePart
ElsePart	-> else Stmt
IO	-> print (str) print (identifier) read (identifier)
ReturnStmt	-> return Expr return
CompoundStmt	-> { StmtList }
StmtList	-> StmtList Stmt ϵ
Expr	-> Attr Rvalue FuncCall
Attr	-> identifier = Expr
Rvalue	-> Rvalue Compare LogicalOr LogicalOr
Compare	-> == < > <= >=

```

| !=

LogicalOr    -> LogicalAnd || LogicalOr
              | LogicalAnd

LogicalAnd   -> Pertinence && LogicalAnd
              | Pertinence

Pertinence   -> Pertinence <?> Cartesian
              | Cartesian

Cartesian    -> Cartesian <*> Addition
              | Addition

Addition     -> Addition + Multiplication
              | Addition - Multiplication
              | Multiplication

Multiplication -> Multiplication * Factor
              | Multiplication / Factor
              | Term

Term         -> ( Expr )
              | - Term
              | + Term
              | $ Term
              | ! Term
              | { FactorList }
              | ( Pair )
              | Factor

Factor       -> identifier
              | boolean
              | number
              | character

FactorList   -> FactorList , Factor
              | Factor
              | ε

Pair         -> Factor , Factor

FuncCall     -> identifier ( IdentList )

```

A única alteração relevante realizada foi na regra do comando *if-then-else*, para eliminar os conflitos que a forma anterior causava. (Outras alterações corresponderam à

eliminação da regra vazia pela mesma razão.)

4. Analisador sintático

Compilando e executando o analisador sintático:

- Léxico:
`$ make tokenizer`
- Sintático:
`$ make parser`
`$ make compile`
(Os passos anteriores podem ser realizados de uma só vez com o comando `make`)
- Executando:
`$./cset <input.cset>`

O arquivo de entrada será analisado e serão geradas a tabela de símbolos e a árvore sintática referentes ao programa. Entretanto, estas duas estruturas só serão mostradas ao usuário caso nenhum erro seja encontrado.

4.1. Erros

Erros sintáticos estão relacionados à estrutura incorreta do programa. Trata-se de tokens que foram validados pelo analisador léxico mas aparecem em um local não esperado. Por exemplo, lexicamente, podemos escrever

```
int int;
```

Mas não sintaticamente, pois `int` corresponde a uma palavra reservada de tipo primitivo da linguagem, e depois de sua ocorrência é esperado um token de identificador, ou seja, esta linha não irá corresponder a nenhuma regra da gramática da linguagem, ocasionando um erro sintático.

Para que o analisador sintático possa identificar o maior número de erros possíveis, uma regra adicional foi acrescentada a algumas variáveis para que pudessem lidar com erros. Por exemplo:

```
| error '}' { synerrors++; yyerrok; }
```

Faz parte da variável `function` e toda vez que um erro é encontrado, o mesmo é reportado e o analisador ignora qualquer token que for enviado pelo léxico até encontrar `'}'`.

4.2. Exemplos

Este documento foi entregue em conjunto com 4 exemplos de programas em CSet. Dentre eles, 2 contendo códigos lexicamente e sintaticamente corretos, e 2 com erros..

- Corretos: *example(1,2).cset*
- Com erros: *error_example(1,2).cset*

Erros:

- Arquivo 1:
 - Erro sintático, linha 3: o tipo `set` só está definido para um argumento.

- Erro léxico, linha 3: token de identificador não deve começar com dígitos.
 - Erro léxico, linha 4: aspas sem fechamento.
- Arquivo 2:
 - Erro sintático, linha 11: falta um ponto e vírgula do final do comando.

Por causa da tentativa de fazer o sintático detectar o maior número de erros possíveis, alguns “falsos positivos” podem ser gerados ao analisar um arquivo.

5. Considerações finais

A ferramenta *Bison* auxiliou em grande parte do processo de construção do analisador sintático. Algumas dificuldades foram encontradas ao lidar com os conflitos gerados pela gramática original, mas todos foram resolvidos.

Referências

- [1] A. V. Abo, M. S. Lam, R. Sethi, J. D. Ullman, *Compilers - Principles, Techniques and Tools* 2nd ed. 1986
- [2] <https://www.gnu.org/software/bison/manual/>¹

¹ Consultado ao longo do desenvolvimento do analisador (2/10 - 8/10/2015).